

Prospective Reward Modeling

面向下游策略效用的奖励学习

局部后悔、奖励等价类与 Fisher 修正的单步自然梯度

理论与实验报告 2026 年 8 月 1 日

摘要

标准 BT-RM 通过最大似然拟合历史偏好标签；但在受限奖励类和受限策略类下，偏好概率拟合得好并不必然导致下游策略效用最优。本文将奖励学习重新定义为 fixed reference policy、fixed policy tangent、fixed one-step optimizer 下的下游效用最大化问题。全局效用是双层优化，难以直接训练；在参考策略附近作 Taylor-Fisher 局部化后，得到闭式目标

$$\widetilde{\text{Reg}}(r) = \frac{1}{2\beta} \|A_0(r - r^*)\|_{F_0^\dagger}^2.$$

该式刻画的是概率加权 reward error 在 policy-visible 空间的正交投影，而不是两个 Bernoulli 偏好分布的 KL。由此产生奖励等价类：若受限奖励类与真实奖励等价类相交，则无需恢复真实奖励本身；若无交集，则应选择局部近似下效用最高的可实现等价类。为落地到 pairwise preference 数据，ProRM 使用同一 pair 的重复条件独立标注构造无偏 margin 统计量，并通过 Fenchel 对偶得到可训练的 Fisher-GMM min-max 目标。有限样本实现用 train-only prompt cross-fit 选择跨 seed、跨 reward source 共享的 Fisher 正则逆，并在同一 β 下比较 MLE-RM、ProRM 与 oracle 所诱导的单步自然梯度策略。在 $\beta \in \{0.1, 0.2, 0.3\}$ 上，三 seed 聚合均给出 $J_{\text{tab}} > J_{\text{Pro}} > J_{\text{oracle}} > J_{\text{MLE}} > J_{\pi_0}$ ，且 Pro 在每个 seed 上均优于 MLE 与 oracle；与此同时，ProRM 的 held-out NLL、奖励 MSE 与局部近似 regret 均差于 MLE-RM，揭示了清晰的 reward-model 泛化缺口。本文据此将奖励层诊断与下游 policy 结论严格分开。

关键词：奖励建模；策略效用；奖励等价类；Fisher 几何；自然梯度

主要记号

r^*, r_ϕ	真实/操作性 oracle 奖励与受限奖励模型	π_0, π_θ	参考策略与更新后策略
A_0	reward 误差到 policy tangent 的局部映射	F_0	π_0 处的 population Fisher 几何
β	理论与实验 J 中 forward-KL 的共同惩罚系数	$\hat{F}_\lambda$	train-only 阻尼经验 Fisher
λ_{rel}	经验 Fisher 逆的相对 damping	δ	固定 LoRA-B tangent 中的一步参数更新

1 局部策略效用与奖励等价类

1.1 问题设定：偏好拟合与下游效用的错位

把 prompt-response 支持上的真实奖励写成 $r^* \in \mathbb{R}^m$ ，局部策略参数写成 $\theta \in \mathbb{R}^d$ ，奖励模型参数写成 $\phi \in \mathbb{R}^p$ 。在 LLM 后训练中，典型关系是

$$m \gg d \gg p.$$

$m \gg d$ 表示策略不可能利用 reward 空间所有方向； $d \gg p$ 表示受限奖励模型又无法表达所有 policy-visible 方向。因此，最小化 reward pointwise error 或 BT likelihood 都不是天然正确的目标。正确对象应是：

用 r_ϕ 训练出来的策略，在真实 r^* 下的效用。

这与 decision-aware 的 “predict, then optimize” 原则一致：预测误差应由其诱导的决策损失评价 [1]。已有 RLHF 理论研究了 pairwise/ K -wise reward MLE、pessimism 及两阶段 RLHF 与 DPO 的统计差异 [5, 7, 8]；近期工作进一步刻画了 representation misspecification、条件等价与局部自然梯度结构 [9, 10, 12]。本文保留显式 reward model，聚焦一个不同问题：受限奖励类中，应该学习哪一个对下游 policy 有效的奖励代表元。

给定参考策略 $\pi_0 = \pi_{\theta_0}$ 和 KL 系数 $\beta > 0$ ，并预先固定包含初始化、随机性与 tie-break 的下游优化器选择映射 $\mathcal{A}$ ，定义

$$J(\theta; r) = \mathbb{E}_{x \sim \rho, y \sim \pi_\theta(\cdot | x)} [r(x, y)] - \beta \mathbb{E}_{x \sim \rho} D_{\text{KL}}(\pi_\theta(\cdot | x) \| \pi_0(\cdot | x)), \quad (1)$$

$$\theta_r = \mathcal{A}(r) \in \arg \max_{\theta} J(\theta; r), \quad U(r) = J(\theta_r; r^*), \quad (2)$$

$$\text{Reg}(r) = U(r^*) - U(r). \quad (3)$$

这是最自然的下游效用定义，但 $r \mapsto \theta_r \mapsto U(r)$ 是全局双层优化，不适合作为第一阶段监督训练目标。

1.2 Taylor–Fisher 局部化与闭式后悔

令

$$d_0(x, y) = \rho(x)\pi_0(y | x), \quad s_0(x, y) = \nabla_{\theta} \log \pi_{\theta_0}(y | x).$$

把所有 score 作为列组成 $A_{\theta_0} \in \mathbb{R}^{d \times m}$ ，并定义

$$D_0 = \text{diag}(d_0), \quad A_0 = A_{\theta_0} D_0, \quad F_0 = A_{\theta_0} D_0 A_{\theta_0}^\top = \mathbb{E}_{d_0} [s_0 s_0^\top].$$

这里 F_0 是参考策略处的 Fisher 几何 [3]。在 θ_0 附近令 $\delta = \theta - \theta_0$ 。对 reward expectation 保留一阶、对 KL 保留二阶，则 quadratic surrogate 为

$$J(\theta; r) \approx C(r) + \delta^\top A_0 r - \frac{\beta}{2} \delta^\top F_0 \delta.$$

局部最优方向为

$$\delta_r = \frac{1}{\beta} F_0^\dagger A_0 r.$$

代入真实奖励 r^* 的局部效用并完成平方，得到

$$\widetilde{\text{Reg}}(r) = \frac{1}{2\beta} (A_0(r - r^*))^\top F_0^\dagger (A_0(r - r^*)). \quad (4)$$

这就是 ProRM 的理想 population surrogate。它不是任意全局最优点上的恒等式；若固定优化器停留在同一光滑 local branch 且 $\delta = O(\beta^{-1})$ ，则原非线性 regret 的 leading term 为 eq. (4)，余项为 $O(\beta^{-2})$ 。

1.3 奖励等价类：从真实奖励到等价类

定义局部奖励等价关系

$$r_1 \sim r_2 \iff A_0 r_1 = A_0 r_2.$$

等价类为

$$[r] = r + \text{Null}(A_0).$$

同一等价类中的所有奖励诱导相同的局部 surrogate 策略方向和相同的 leading-order 局部效用。于是 realizability 应分成三层：

1. 完整可实现： $r^* \in \mathcal{R}$ 。BT-RM 与 ProRM 在 population 下可一致。
2. 等价类可实现： $r^* \notin \mathcal{R}$ ，但 $\mathcal{R} \cap [r^*] \neq \emptyset$ 。此时无需恢复 r^* ，只需命中真实等价类。
3. 等价类无交集： $\mathcal{R} \cap [r^*] = \emptyset$ 。此时应选择

$$r_{\text{Pro}} \in \arg \min_{r \in \mathcal{R}} \|A_0(r - r^*)\|_{F_0}^2,$$

即局部 surrogate 效用最高的可实现等价类。

命题：局部奖励等价类

两阶段局部 RLHF 的核心不是“学习真实奖励向量”，而是“学习真实奖励在 policy quotient space 中的像”。这将可实现条件从 $r^* \in \mathcal{R}$ 放松为 $\mathcal{R} \cap [r^*] \neq \emptyset$ 。

1.4 几何解释：正交投影与 Bernoulli-KL 投影

令 $B_0 = A_{\theta_0} D_0^{1/2}$ ， $h = r - r^*$ 。由于 $F_0 = B_0 B_0^\top$ ，有

$$\|A_0 h\|_{F_0^\dagger}^2 = h^\top D_0^{1/2} B_0^\top (B_0 B_0^\top)^\dagger B_0 D_0^{1/2} h \quad (5)$$

$$= \left\| P_{\text{row}(B_0)} D_0^{1/2} h \right\|_2^2. \quad (6)$$

因此

$$\widetilde{\text{Reg}}(r) = \frac{1}{2\beta} \left\| P_{\text{row}(A_{\theta_0} D_0^{1/2})} D_0^{1/2} (r - r^*) \right\|_2^2. \quad (7)$$

这说明 ProRM 最小化的是：概率加权 reward error 在 policy-visible row space 上的正交投影长度。

在 Bradley-Terry 模型 [2] 下，BT-RM 的 population excess NLL（即减去与 r 无关的 truth entropy 后的部分）为

$$\mathcal{D}_{\text{BT}}(r) = \mathbb{E}_{e \sim Q_0} d_{\text{KL}}(\text{Bern}(\sigma(\Delta r^*(e))) \parallel \text{Bern}(\sigma(\Delta r(e)))), \quad (8)$$

其中 $Q_0 = \rho \pi_0 \pi_0$ 。它会拟合所有 preference-visible 方向，包括 policy-invisible 的 $\text{Null}(A_0)$ 成分。因此，在受限奖励类中，eq. (7) 与 eq. (8) 一般给出不同投影。

2 可解析例证：奖励等价类与投影错位

2.1 模型设定

有三个等概率 context x_1, x_2, x_3 ，每个 context 有两个 response $\{+, -\}$ ，reference policy 均匀。策略只有二维局部参数：

$$\pi_\theta(+ | x_j) = \sigma(2z_j^\top \theta), \quad z_1 = e_1, z_2 = e_2, z_3 = 0, \quad \theta_0 = 0.$$

因此 x_1, x_2 是 policy-visible, x_3 是 preference-visible 但 policy-invisible: 它能出现在偏好数据里，却无法被当前 policy tangent 改变。

用 margin $d_j = r(x_j, +) - r(x_j, -)$ 表示奖励，取中心化代表 $r_d(x_j, \pm) = \pm d_j/2$ 。则

$$A_0 r_d = \frac{1}{6}(d_1, d_2)^\top, \quad F_0 = \frac{1}{3}I_2. \quad (9)$$

所以奖励等价类只由

$$g(d) = (d_1, d_2)$$

决定； d_3 完全在 $\text{Null}(A_0)$ 中。

令受限奖励类为一维共享特征

$$\mathcal{R} = \{d(w) = (w, w, w) : w \in \mathbb{R}\}.$$

直观解释：奖励模型只有一个全局强度参数 w ，必须对三个 context 给出同一个 margin；但策略实际只用得上前两个 margin。

2.2 BT-RM 与 ProRM 的闭式解

令

$$\ell(z, t) = \log(1 + e^t) - \sigma(z)t.$$

完整自然 $\mathcal{Q}_0$ 下，BT population NLL 为

$$L_{\text{BT}}(w) = \frac{1}{2} \log 2 + \frac{1}{6} \sum_{j=1}^3 \ell(d_j^*, w), \quad (10)$$

所以

$$w_{\text{BT}} = \text{logit} \left(\frac{\sigma(d_1^*) + \sigma(d_2^*) + \sigma(d_3^*)}{3} \right). \quad (11)$$

BT-RM 会被三个 context 的 preference probability 共同决定，包括 policy-invisible 的 d_3^* 。

ProRM 只看 $g(d) = (d_1, d_2)$ 。由 eq. (9)，

$$\widetilde{\text{Reg}}(w) = \frac{(w - d_1^*)^2 + (w - d_2^*)^2}{24\beta}, \quad w_{\text{Pro}} = \frac{d_1^* + d_2^*}{2}. \quad (12)$$

ProRM 完全忽略 d_3^* ，因为 x_3 对当前局部策略不可控。

2.3 三类可实现性情形

固定 $\beta = 8$ 。三个 case 只改变真实 margin d^* ，其余设置完全相同。

Case	几何含义	d^*	w_{BT}	w_{Pro}
I	完整真实奖励可实现: $d^* = d(2) \in \mathcal{R}$	$(2, 2, 2)$	2.000	2.000
II	等价类可实现: $d^* \notin \mathcal{R}$, 但 $d(2) = (2, 2, 2) \in \mathcal{R} \cap [d^*]$	$(2, 2, 6)$	2.438	2.000
III	等价类无交集: 真实 visible 点 $(6, 0)$ 不在直线 (w, w) 上	$(6, 0, -6)$	0.000	3.000

表 1 同一最小模型下的三个 case。Case II 中, policy-invisible 的强偏好 $d_3^* = 6$ 会拉动 BT-RM, 却不应改变策略; Case III 中, ProRM 选择 visible quotient space 中的正交投影。




图 1 最直观的 quotient-space 图。横纵轴是 policy 能改变的两个 context; d_3 不画出, 因为它属于 $\text{Null}(A_0)$ 。BT-RM 会被 d_3 影响, ProRM 不会。

Case	方法	自然 Q_0 NLL ↓		局部 regret ↓		真实 regret ↓	
		数值	优者	数值	优者	数值	优者
I	BT-RM	0.5292	✓	0	✓	0	✓
I	ProRM	0.5292	✓	0	✓	0	✓
II	BT-RM	0.4863	✓	0.00200		0.00196	
II	ProRM	0.4903		0	✓	0	✓
III	BT-RM	0.6931	✓	0.1875		0.1833	
III	ProRM	1.1209		0.0938	✓	0.0901	✓

表 2 三 case 的 population 结果。Case II: BT-RM 有更低 NLL, 但 ProRM 达到零 regret。Case III: ProRM 的 NLL 明显更差, 但将局部 regret 降低 50%, 真实 regret 降低约 51%。

真实 regret 在原始非线性 KL 正则目标下计算:

$$\text{Reg}_{\text{true}}(w) = \frac{\beta}{3} \left[D_{\text{KL}}(\text{Bern}(\sigma(w/\beta)) \parallel \text{Bern}(\sigma(d_1^*/\beta))) + D_{\text{KL}}(\text{Bern}(\sigma(w/\beta)) \parallel \text{Bern}(\sigma(d_2^*/\beta))) \right].$$

x_3 不出现, 因为当前 policy tangent 无法改变它。这一例证得到如下结论:

例证结论

policy-invisible 的偏好信号可以显著改善 BT likelihood, 却不应该改变下游策略; 当 reward class 受限时, BT-RM 可能为了拟合这些无效偏好而选择错误等价类, ProRM 则直接在 policy-visible quotient space 中做效用投影。

3 ProRM 估计与 Fisher 修正的单步 NGD 主实验**3.1 偏好数据、无偏边际统计量与 ProRM 估计**

ProRM 使用两类数据对象。

- 节点数据: $(x, y) \sim d_0$, 用于估计 Fisher。工程中保存分数行 $s_0(x, y)$, 形成矩阵 S , 并以

$$\widehat{F}_0 u = \frac{1}{n_F} S^\top (S u)$$

计算 Fisher-向量乘积。

- 边数据: $e = (x, y, y') \sim Q_0$, 令

$$z_0(e) = s_0(x, y) - s_0(x, y'), \quad t_\phi(e) = \Delta r_\phi(e).$$

在同一 e 上采集条件独立的重复标注。若 $a_j | e \sim \text{Bernoulli}(\sigma(\Delta r^*(e)))$, 与标注独立的 N 满足 $\Pr(N = n) = (1 - \gamma)\gamma^{n-1}$ ($n \geq 1$), 且 $S_N = \sum_{j=1}^N a_j$, 定义

$$H(e) = \sum_{k=1}^N \frac{\binom{S_N}{k} - \binom{N-S_N}{k}}{k\gamma^{k-1}\binom{N}{k}}.$$

则 $\mathbb{E}[H(e) | e] = \Delta r^*(e)$ 。实验锁定 $\gamma = 0.9$, 并通过 oracle 变换保证 $p^* \in [0.25, 0.75]$, 因而该估计量具有有限二阶矩; 本文不进一步声称轻尾性或有限四阶矩。

更一般地, 比较对的选择会改变下游信息几何与样本效率 [11]。本实验固定候选 0-1 的规范边, 目的是隔离 BT-MLE 与 ProRM 的目标差异, 而非声称该比较对设计最优。

由配对恒等式可得

$$A_0 r = \frac{1}{2} \mathbb{E}_{Q_0} [z_0(e) \Delta r(e)], \quad F_0 = \mathbb{E}_{d_0} [s_0 s_0^\top].$$

因此, 可观测矩为

$$\widehat{m}_\phi = \frac{1}{2n_E} \sum_{i=1}^{n_E} z_i(t_\phi(e_i) - h_i).$$

经验 ProRM 目标采用岭正则化。令

$$\widehat{\mu}_F = \frac{1}{d} \text{tr}(\widehat{F}_0), \quad \widehat{F}_\lambda = \widehat{F}_0 + \lambda_{\text{rel}} \widehat{\mu}_F I,$$

则

$$\min_{\phi} \max_v \frac{1}{\beta} \left[v^\top \widehat{m}_\phi - \frac{1}{2} v^\top \widehat{F}_\lambda v \right]. \quad (13)$$

在每个外层步骤中，先利用全部边计算 $\hat{m}_\phi$ ，再以 PCG 求解

$$\hat{F}_\lambda v = \hat{m}_\phi,$$

随后将 v 脱离计算图，依据包络定理给出的梯度更新奖励模型。对固定 ϕ ，内层是凹二次问题，因而

$$v^*(\phi) = \hat{F}_\lambda^{-1} \hat{m}_\phi, \quad \mathcal{L}_{\text{profile}}(\phi) = \frac{1}{2\beta} \hat{m}_\phi^\top \hat{F}_\lambda^{-1} \hat{m}_\phi.$$

虽然 eq. (13) 写成极小-极大形式，锁定实现并非同时执行小批量梯度下降/上升。每次外层更新均以全数据矩重新通过 PCG 求得近精确的 v^* ，然后对 ϕ 执行一次 AdamW 下降。小批量仅用于等价的梯度累积与显存控制，不改变全数据梯度。直接对 v 执行随机上升可作为近似鞍点算法，但会引入对偶学习率、内层滞后与收敛误差，故本实验不采用。当 reward head 为线性模型时，上述剖面目标是凸二次问题；BT-RM 则对应凸 logistic regression。

此处的 population 理论对象仍为 $F_0^\dagger$ 。 $\hat{F}_\lambda^{-1}$ 只是有限样本下的稳定化估计，不应解释为新的 population estimand。正则化强度必须仅依据训练数据选择，且选定后对所有随机种子和奖励来源共享；否则，方法特定的几何会与奖励质量发生混杂。

理论与有限样本实现的边界

Population 理论使用 $F_0^\dagger$ ；工程实现使用 train-only 的 $\hat{F}_\lambda^{-1}$ 。后者是稳定经验逆的估计方案，不是对 population estimand 的重新定义。测试集只负责冻结后的评价，不进入 reward 拟合、Fisher 选择或方向求解。

3.2 验证问题与冻结设计

本工程是 exact- Δr^* 的受控机制实验：固定 prompt、六候选池、操作性 oracle、reward feature 与 rank-4 LoRA- B tangent，只改变 MLE-RM 与 ProRM 的训练目标。正式比较使用同一个 $\hat{F}_\lambda$ 和同一个 β ；oracle-NGD 是机制参照，tabular policy 是该有限候选池上的闭式最优上界。

对象	冻结设置
Seeds 与数据隔离	Seeds 20261001–20261003；train/validation/test 为 3072/512/512。train 用于拟合、Fisher 与方向，test 仅用于本节评价。
Prompt 与候选	MultiPref 只提供 prompts； π_0 = Qwen2.5-1.5B-Instruct；每个 prompt 有 $M = 6$ 个独立生成候选。
Operational oracle	Skywork-Reward-V2-Llama-3.2-3B 的 scalar score 经 train-only 稳健仿射变换得到 r^* ；它不是潜在人类效用。
Reward class	冻结 Qwen response feature 加无 bias 的 1536 维线性 head。
Policy tangent	最后一层 q_proj/v_proj 的 rank-4 LoRA- B ，维度 7168；LoRA-A 与 backbone 固定。
Fisher	Train nodes 的 raw second moment；五折 train-only cross-fit 从 $\lambda_{\text{rel}} \in \{0.1, 1, 10\}$ 选择共享值 10。
主报告 β	$\{0.1, 0.2, 0.3\}$ ；0.2 为中心条件，0.1/0.3 为两侧敏感性条件。

表 3 Main Experiment v1 的冻结对象。模型身份、数据顺序、精度和上游哈希均由 receipt 与 integrity audit 约束。

3.3 Fisher 修正与共同正则系数下的单步 NGD

令 $S \in \mathbb{R}^{N \times d}$ 的行是 train nodes 上的 score, 定义

$$\hat{F} = \frac{1}{N} S^\top S, \quad \hat{\mu}_F = \frac{1}{d} \text{tr}(\hat{F}), \quad \hat{F}_\lambda = \hat{F} + \lambda_{\text{rel}} \hat{\mu}_F I. \quad (14)$$

这里的 damping 只服务于稳定求逆。对 reward source $m \in \{\text{MLE}, \text{Pro}, \text{oracle}\}$, 先在 train 上冻结

$$\hat{g}_m = A_{\text{train}} \hat{r}_m, \quad d_m = \hat{F}_\lambda^{-1} \hat{g}_m, \quad \delta_m(\beta) = \frac{1}{\beta} d_m. \quad (15)$$

因此该更新是固定正则系数下的一步 damped NGD, 而不是把 KL 约束取等号后再校准的 TRPO。三种方向共享同一 Fisher 估计与阻尼, β 只控制共同更新尺度。

在 test prompt x_p 的六个冻结候选上, 令 s_{pi} 为候选 i 的 policy score, 则四个参数化 policy 与 tabular optimum 分别为

$$\pi_m(i | x_p) = \frac{\exp(s_{pi}^\top d_m / \beta)}{\sum_j \exp(s_{pj}^\top d_m / \beta)}, \quad m \in \{\text{MLE}, \text{Pro}, \text{oracle}\}, \quad (16)$$

$$\pi_{\text{tab}}(i | x_p) = \frac{\pi_0(i | x_p) \exp(r_{pi}^* / \beta)}{\sum_j \pi_0(j | x_p) \exp(r_{pj}^* / \beta)}. \quad (17)$$

本实验候选由 π_0 独立生成, 有限池上的 reference 权重为 $1/M$ 。

3.4 唯一正式评价指标

Reward 层只保留三个诊断量。令 $q_{pe}^* = \sigma(\Delta r_{pe}^*)$ 、 $q_{pe}^m = \sigma(\Delta \hat{r}_{pe}^m)$, 则

$$\text{NLL}_m = -\frac{1}{|\mathcal{E}_{\text{test}}|} \sum_{p,e} [q_{pe}^* \log q_{pe}^m + (1 - q_{pe}^*) \log(1 - q_{pe}^m)], \quad (18)$$

$$\text{MSE}_m = \frac{1}{PM} \sum_{p,i} [(\hat{r}_{pi}^m - \bar{r}_p^m) - (r_{pi}^* - \bar{r}_p^*)]^2, \quad (19)$$

$$\widetilde{\text{Reg}}_{m,\beta} = \frac{1}{2\beta} \Delta A_{m,\text{test}}^\top \hat{F}_{\lambda,\text{train}}^{-1} \Delta A_{m,\text{test}}, \quad \Delta A_{m,\text{test}} = A_{\hat{r}_m,\text{test}} - A_{r^*,\text{test}}. \quad (20)$$

NLL 与 MSE 不依赖 β ; 近似 regret 按 $1/\beta$ 精确缩放。它使用 test reward moment 评价泛化, 但保留训练阶段已冻结的 Fisher, 不在 test 上重新选择几何。

Policy 层对每个 π 定义

$$R(\pi) = \frac{1}{P} \sum_p \sum_i \pi(i | x_p) r_{pi}^*, \quad (21)$$

$$K(\pi) = \frac{1}{P} \sum_p D_{\text{KL}}(\pi(\cdot | x_p) \| \pi_0(\cdot | x_p)), \quad (22)$$

$$J_\beta(\pi) = R(\pi) - \beta K(\pi), \quad (23)$$

$$\Delta J_\beta(\pi) = J_\beta(\pi_{\text{tab}}) - J_\beta(\pi), \quad (24)$$

$$\beta K_{\text{tab}}(\pi) = \frac{\beta}{P} \sum_p D_{\text{KL}}(\pi(\cdot | x_p) \| \pi_{\text{tab}}(\cdot | x_p)), \quad (25)$$

$$J_{\text{close}}(\beta) = \frac{\beta}{P} \sum_p \log \left[\frac{1}{M} \sum_i \exp(r_{pi}^* / \beta) \right]. \quad (26)$$

Reward 指标 ↓	MLE-RM	ProRM
Soft BTL NLL	0.683446 ± 0.001089	0.732853 ± 0.003183
中心化 reward MSE	0.302047 ± 0.008749	0.498254 ± 0.020681
$\widetilde{\text{Reg}}_{\beta=0.1}$	0.343710 ± 0.007908	0.632512 ± 0.048955
$\widetilde{\text{Reg}}_{\beta=0.2}$	0.171855 ± 0.003954	0.316256 ± 0.024477
$\widetilde{\text{Reg}}_{\beta=0.3}$	0.114570 ± 0.002636	0.210837 ± 0.016318

表 4 Reward 层 held-out evaluation, 均报告三 seed mean ± sample SD。ProRM 的三个指标均较差, 诊断为 reward-moment 泛化不足; 该负结果与下游 policy 评价分开解释。

Policy	R	K	J	ΔJ	$\beta D_{\text{KL}}(\pi \ \pi_{\text{tab}})$
π_{tab}	0.728422 ± 0.021935	1.349120 ± 0.011587	0.593510 ± 0.023060	0.000000 ± 0.000000	0.000000 ± 0.000000
π_{Pro}	0.051489 ± 0.020033	0.211923 ± 0.052144	0.030297 ± 0.017217	0.563213 ± 0.006750	0.563213 ± 0.006750
π_{oracle}	0.052715 ± 0.019606	0.245985 ± 0.050302	0.028116 ± 0.016883	0.565393 ± 0.007079	0.565393 ± 0.007079
π_{MLE}	0.031496 ± 0.024754	0.092737 ± 0.023127	0.022223 ± 0.023937	0.571287 ± 0.001110	0.571287 ± 0.001110
π_0	-0.005947 ± 0.024932	0.000000 ± 0.000000	-0.005947 ± 0.024932	0.599457 ± 0.005111	0.599457 ± 0.005111

表 5 $\beta = 0.1$ 的冻结 test-candidate policy evaluation; 均报告三 seed mean ± sample SD。Reward 完整排序与 utility 完整排序分别在 3/3 和 2/3 个 seed 成立。

有限候选池上有两个严格恒等式

$$\boxed{J_{\beta}(\pi_{\text{tab}}) = J_{\text{close}}(\beta)}, \quad \boxed{\Delta J_{\beta}(\pi) = \beta K_{\text{tab}}(\pi)}. \quad (27)$$

因此 ΔJ 与 βK_{tab} 是同一 gap 的两种独立实现, 用于交叉校验, 不是两项独立证据。

3.5 结构化工程链路与可接续边界



图 2 本轮主实验的依赖闭包。上游 artifact、reward heads、Fisher 与方向均未重算; 只扩展共同 β evaluation 及其下游聚合、审计与报告。

每个阶段的 immutable receipt 与内容哈希决定能否接续。只有最早受影响阶段及其科学下游需要重算; 没有受影响且验证通过的上游不重复生成。最终 Git bundle 同时保留三个 seed 的完整 evaluation JSON、aggregate、audit、archive manifest、机器可读 summary 与由 summary 确定性生成的结果表。

Policy	R	K	J	ΔJ	$\beta D_{\text{KL}}(\pi \ \pi_{\text{tab}})$
π_{tab}	0.674758 ± 0.022973	0.985291 ± 0.003741	0.477700 ± 0.023708	0.000000 ± 0.000000	0.000000 ± 0.000000
π_{Pro}	0.026396 ± 0.023099	0.061705 ± 0.017558	0.014055 ± 0.021328	0.463645 ± 0.003405	0.463645 ± 0.003405
π_{oracle}	0.027781 ± 0.022902	0.073307 ± 0.018050	0.013120 ± 0.021081	0.464580 ± 0.003446	0.464580 ± 0.003446
π_{MLE}	0.013925 ± 0.024976	0.024840 ± 0.006720	0.008957 ± 0.024645	0.468743 ± 0.002529	0.468743 ± 0.002529
π_0	-0.005947 ± 0.024932	0.000000 ± 0.000000	-0.005947 ± 0.024932	0.483647 ± 0.005097	0.483647 ± 0.005097

表 6 $\beta = 0.2$ 的冻结 test-candidate policy evaluation; 均报告三 seed mean $\pm$ sample SD。Reward 完整排序与 utility 完整排序分别在 3/3 和 3/3 个 seed 成立。

Policy	R	K	J	ΔJ	$\beta D_{\text{KL}}(\pi \ \pi_{\text{tab}})$
π_{tab}	0.610330 ± 0.023082	0.724503 ± 0.003993	0.392979 ± 0.024036	0.000000 ± 0.000000	0.000000 ± 0.000000
π_{Pro}	0.016234 ± 0.023759	0.028349 ± 0.008383	0.007729 ± 0.022618	0.385250 ± 0.003042	0.385250 ± 0.003042
π_{oracle}	0.017326 ± 0.023660	0.033821 ± 0.008749	0.007180 ± 0.022474	0.385800 ± 0.002927	0.385800 ± 0.002927
π_{MLE}	0.007493 ± 0.024975	0.011207 ± 0.003107	0.004132 ± 0.024789	0.388848 ± 0.003047	0.388848 ± 0.003047
π_0	-0.005947 ± 0.024932	0.000000 ± 0.000000	-0.005947 ± 0.024932	0.398927 ± 0.004887	0.398927 ± 0.004887

表 7 $\beta = 0.3$ 的冻结 test-candidate policy evaluation; 均报告三 seed mean $\pm$ sample SD。Reward 完整排序与 utility 完整排序分别在 3/3 和 3/3 个 seed 成立。

3.6 Main Experiment v1 结果

下游 policy 结论

在 $\beta = 0.1, 0.2, 0.3$ 的三 seed 聚合均值上, 均观察到

$$R_{\text{tab}} > R_{\text{oracle}} > R_{\text{Pro}} > R_{\text{MLE}} > R_{\pi_0}, \quad J_{\text{tab}} > J_{\text{Pro}} > J_{\text{oracle}} > J_{\text{MLE}} > J_{\pi_0}.$$

逐 seed 检查中, Pro 的 J 在全部 9/9 个 seed $\times \beta$ 条件上同时高于 MLE 与 oracle; 完整 J 链在 $\beta = 0.1$ 为 2/3, 在 $\beta = 0.2, 0.3$ 均为 3/3, 唯一偏离来自一个 seed 的 oracle 与 MLE 次序互换, 不影响 Pro-MLE 主比较。中心条件 $\beta = 0.2$ 下, Pro 相对 MLE 的平均 J 优势为 0.005098; Pro 与 oracle 的平均 J 差为 0.000935。因此 Pro-NGD 明显优于 MLE-NGD, 并保持接近 oracle-NGD 的 regularized utility。

Reward 层负结果: RM 过拟合/泛化不足

ProRM 的 train profiled objective 确实被优化: 三个 seed 上均低于 MLE 投影, 均值由 0.004951 降至 0.002115。但在 held-out test 上, ProRM 的 NLL、centered reward MSE 与近似 regret 全部差于 MLE-RM; 两个 seed 的 Pro head 范数还从 MLE 的约 4.94/3.55 增长到 11.28/11.69。这说明当前主要问题是 reward head 对训练矩目标过拟合、policy-relevant moment 泛化不足, 而不是 PCG、Fisher 求逆或 NGD 公式失效。该问题必须诚实保留为限制; 本轮不以事后加正则化改写结果。

证据等级与外部有效性

$\beta = 0.1, 0.2, 0.3$ 是观察 dense test sweep 后确定的主报告区间, 因此本版属于完整、可审计的探索性主实验, 而不是新 held-out confirmatory test。未来确认性实验应在新 test 前冻结 $\beta = 0.2$ ($0.1/0.3$ 为敏感性)。此外, policy 指标来自冻结六候选池, 不直接等价于多步 PPO/GRPO 或开放式 fresh generation; Skywork 也只是 operational oracle。三个 seed 支持一致性与描述统计, 不支持渐近显著性主张。

Producer commit: 0f51c6a59454e7ad7e4fa9fd09f022feb0598d68

Aggregate SHA-256: fb6967abf4a8b0ca679c6a022c9537a6d1dc471a90187580e110b751605ac930

Audit status: passed; archive manifest SHA-256:

fac001daf941a365d6db4541219e24b26d01e028d9a158e111a092040d097e85.

讨论与结论

ProRM 的理论主线是：奖励模型不应只解释偏好概率，而应最小化它所诱导的下游 policy regret。Taylor–Fisher 局部化把双层效用转化为 policy-visible quotient space 中的投影范数；奖励等价类进一步说明，完整恢复 r^* 并非必要。Main Experiment v1 修正了经验 Fisher 的估计与正则逆，并用共同 β 的单步 NGD 对五个 policy 进行有限候选池评价。结果呈现出一个必须同时报告的张力：ProRM 的 reward-level test 泛化弱于 MLE-RM，但 Pro-NGD 的下游 J 在三个 β 、三个 seed 上均优于 MLE-NGD，并接近 oracle-NGD。因而本轮最强结论不是“ProRM 在所有 reward 指标上更好”，而是“即使传统 reward-fit 与局部 proxy 更差，面向决策的训练目标仍可产生更优的下游 regularized utility”。这正是本文理论所强调的评价错位，同时也指出下一轮应直接处理 reward-moment 泛化，而不应掩盖该限制。

参考文献

- [1] A. N. Elmachetoub and P. Grigas. Smart “Predict, then Optimize”. arXiv:1710.08005, 2020 revision.
- [2] R. A. Bradley and M. E. Terry. Rank analysis of incomplete block designs: I. The method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [3] S. Amari. *Information Geometry and Its Applications*. Springer, 2016.
- [4] J. Schulman, S. Levine, P. Abbeel, M. Jordan, and P. Moritz. Trust Region Policy Optimization. *ICML*, PMLR 37, 2015.
- [5] B. Zhu, M. I. Jordan, and J. Jiao. Principled Reinforcement Learning with Human Feedback from Pairwise or K-wise Comparisons. arXiv:2301.11270, 2024.
- [6] X. Wen, J. Lou, Y. Lu, et al. Rethinking Reward Model Evaluation: Are We Barking Up the Wrong Tree? *ICLR*, 2025.
- [7] A. Nika, D. Mandal, P. Kamalaruban, G. Tzannetos, G. Radanović, and A. Singla. Reward Model Learning vs. Direct Policy Optimization: A Comparative Analysis of Learning from Human Preferences. *ICML*, PMLR 235, 2024.
- [8] Z. Li, T. Xu, and Y. Yu. When Is RL Better Than DPO in RLHF? A Representation and Optimization Perspective. *ICLR Tiny Papers*, 2024.
- [9] R. Shi, M. Song, R. Zhou, Z. Zhang, M. Fazel, and S. S. Du. Understanding the Performance Gap in Preference Learning: A Dichotomy of RLHF and DPO. *ICML*, PMLR 306, 2026.
- [10] Z. Yang, Y. Zhang, W. Xue, D. Fang, B. Han, and Y. Guo. Conditional Equivalence of DPO and RLHF: Implicit Assumption, Failure Modes, and Provable Alignment. *ICML*, PMLR 306, 2026.
- [11] J. Han, V. Goyal, and W. Ma. Which Pairs to Compare for LLM Post-Training? arXiv:2606.19607, 2026.
- [12] A. Gopalan, S. Ray Chowdhury, and D. Banerjee. Why DPO Is a Misspecified Estimator and How to Fix It. arXiv:2510.20413, 2025.